Laboratorio 4 – Extracción de características en texto

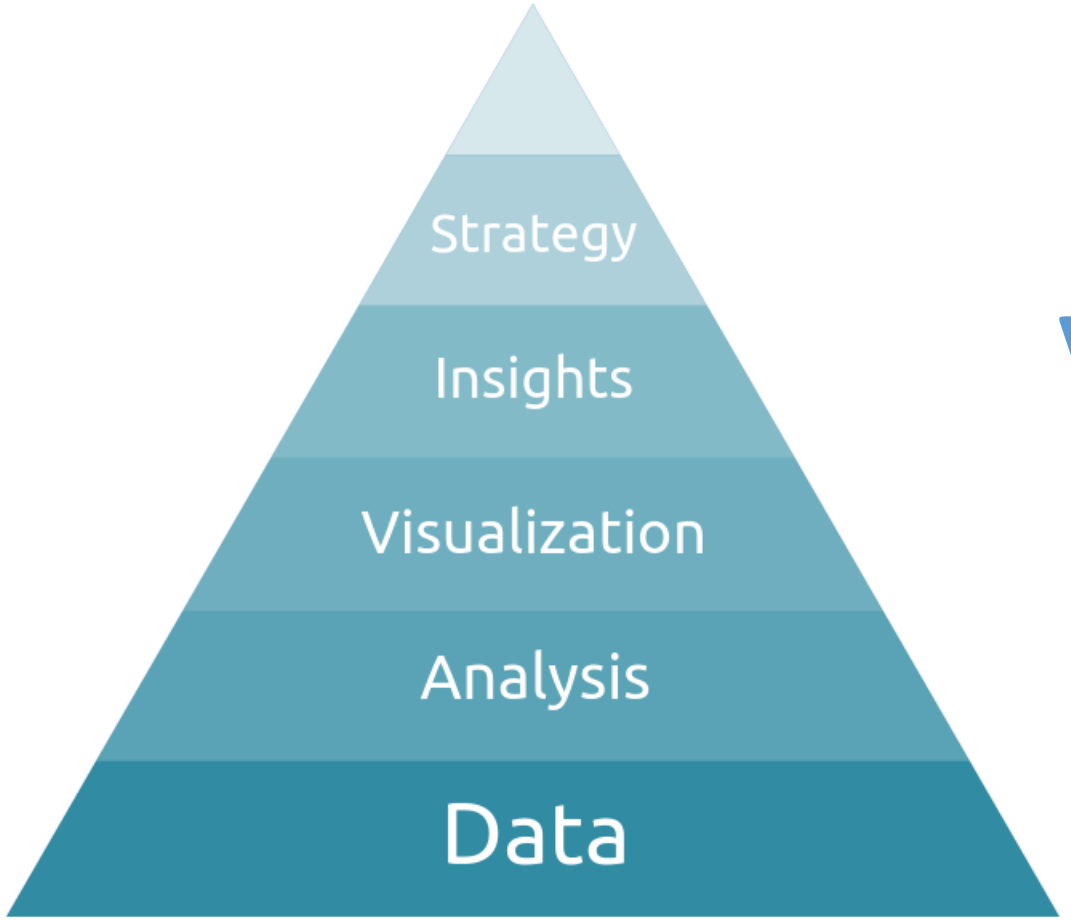

Análisis y Visualización de datos

Grado en Ingeniería
y Sistemas de Datos

Javier Guinea, Federico Álvarez, Francisco Moreno, Alberto Belmonte

Escuela Técnica Superior de Ingenieros de Telecomunicación - UPM

Laboratorio de hoy

- En el laboratorio de hoy vamos a explorar la tokenización y vectorización.
- La tokenización es el proceso de separación de texto en palabras (tokens) para tareas de procesamiento de texto.
- La vectorización (embedding) es el proceso de convertir las palabras o textos completos en vectores que codifiquen alguna información interesante del texto (semántica, frecuencia).

Vectorización

- No existe un embedding único para cada palabra.
- Depende del contexto.

Generado con texto aleatorio

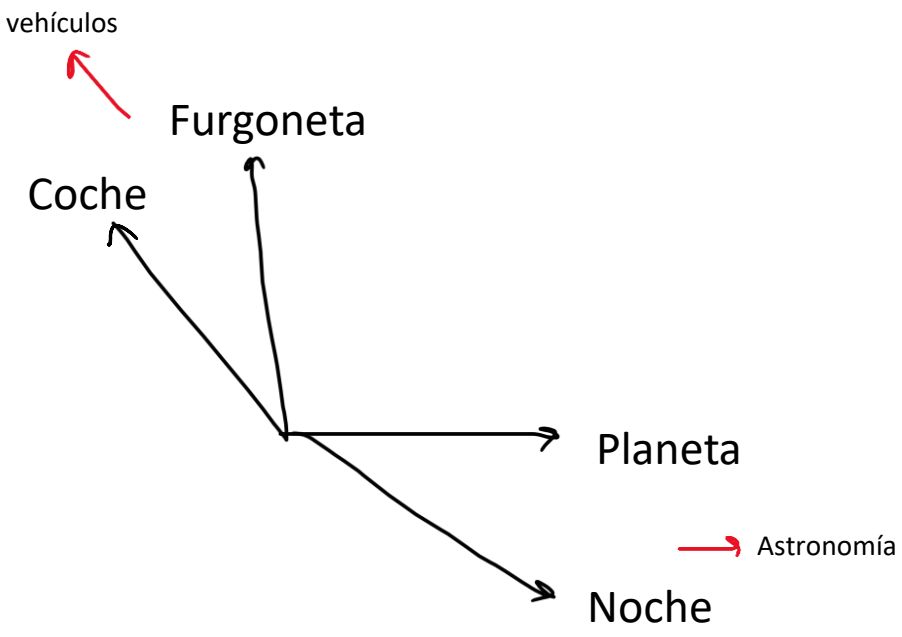

Generado con rimas

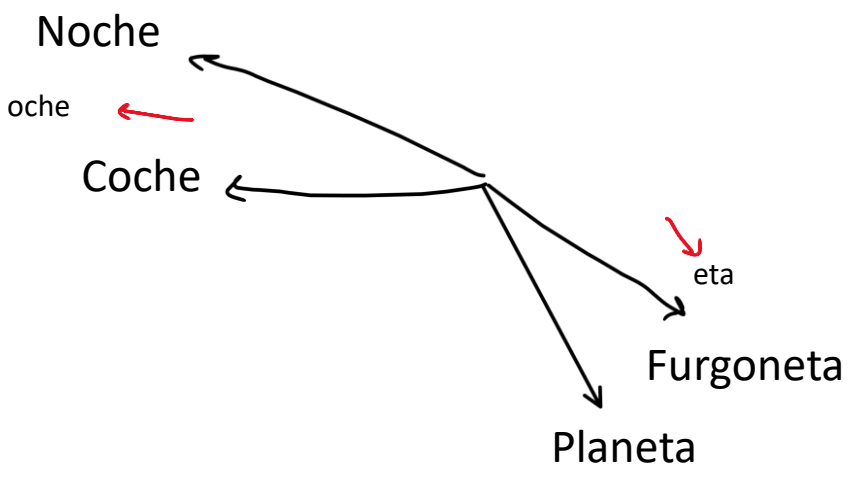

Simlitud por cosenos

- La **similitud coseno** mide cuánto se parecen dos vectores calculando el coseno del ángulo entre ellos.
- Varía entre -1 (opuestos), 0 (sin relación) y 1 (idénticos).
- Entre vectores con el mismo signo varía de 0 a 1.
- Es útil cuando no es importante la escala, si no sólo la dirección.
- Muy empleado en NLP.

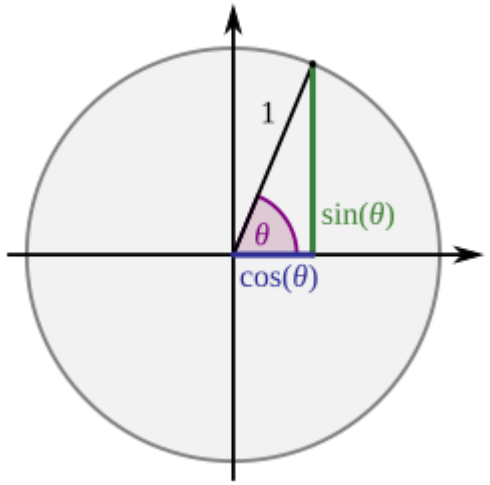

Realización de la práctica

La práctica consta de un notebook y un examen escrito.

• En el notebook hay una serie de cuestiones sobre la práctica que iréis respondiendo conforme la realizáis. Estas cuestiones deben responderse en el propio notebook.

•20’ antes de finalizar la sesión, se os entregará un examen escrito. Debéis entregar el notebook y el examen para puntuaros.